

SALESHEALTH — UN ESTUDIO DE

Comportamiento de compra.

Sobre 5 750 clientes y 20 000 compras, entre 2020 y 2025. Seis capítulos.

- 01 Visión General
- 02 Clientes
- 03 Segmentación
- 04 Productos
- 05 Ficha Cliente
- 06 Metodología

Capítulo VI

VI · METODOLOGÍA

Metodología.

Pipeline ETL, modelo dimensional, trazabilidad de cada KPI a su SQL, justificación de $k = 3$ y de PCA(2), y limitaciones declaradas.


A Pipeline ETL

PUBLIC → STAGING → DWH

Tres pasos secuenciales — orquestados por los notebooks 01_etl_staging → 02_etl_dwh → 03_cltv_calculation → 04_customer_metrics → 05_pca_clustering. El esquema public contiene los datos crudos; staging los normaliza; dwh aplica el modelo dimensional en estrella (ver sección B).

B Modelo dimensional (estrella)

DWH SCHEMA



Dos hechos (ventas y devoluciones) en el centro y cuatro dimensiones en las esquinas. La estrella se carga incrementalmente desde staging.


C Mapa KPI → fórmula → origen

KPI	FÓRMULA	ORIGEN DWH	PARQUET INTERMEDIARIO
Ingresos netos	gross_revenue - returns_value	dwh.fact_sales / fact_returns	—
CLTV	net_revenue × margin × frequency × retention	(notebook 03)	cltv.parquet
Tasa devolución	returns_value / gross_revenue	dwh.fact_returns / fact_sales	—
AOV	gross_revenue / tickets	dwh.fact_sales	customer_metrics.parquet
Cluster	KMeans(k=3) sobre PCA(2)	models/customer_segments.parquet	—
Recencia	max(today) - last_purchase	dwh.fact_sales	customer_metrics.parquet
Margen bruto	Σ margin / Σ subtotal	dwh.fact_sales (margin = subtotal - cost)	—
Frecuencia	count(distinct sale_id) por cliente	dwh.fact_sales	cltv.parquet
Retención	active_months / window_months	(notebook 03)	cltv.parquet
PC1/ PC2	PCA(2) sobre 8 features estandarizadas	models/pca.joblib	models/customer_segments.parquet

Ningún KPI sin papeleta: si alguien pregunta «¿de dónde sale el AOV?», la respuesta está aquí, no en una conversación.


D Justificación de $k = 3$ (curva del codo)

Inertia ~ k



Inertia decrece monótonamente con k. El codo es donde la mejora marginal por añadir un cluster cae bruscamente — en este dataset, $k=3$. Defender la elección con un gráfico es preferible a afirmarla.

Varianza explicada por componente



Resumen

PC1

57.1%

PC2

23.2%

TOTAL 2D

80.3%

objetivo 80% - cumplido

PCA(2) cubre 80.3% de la varianza. La elección de 2 componentes se evalúa contra el objetivo declarado.

F Las 8 features + limitaciones

Features usadas en el clustering

01	net_revenue	Ingresos netos por cliente — escala monetaria base.
02	margin_rate	Margen relativo — separa volumen de rentabilidad.
03	frequency	Recompra — tickets distintos del cliente.
04	retention_rate	Retención — meses activos sobre ventana total.
05	aov	Ticket medio — rev / nº tickets.
06	recency_days	Recencia — días desde la última compra.
07	return_rate	Tasa devolución — fricción del cliente.
08	cltv	CLTV calculado — el output también entra como feature de estabilidad.

Limitaciones declaradas

- 1 **PCA(2)** explica el 80.3% de la varianza. El resto se pierde en el plano.
- 2 **10 clientes con return_rate > 1** — artefacto del Cluster 2 (devoluciones de unidades no contabilizadas como venta).
- 3 **5 000 clientes con frequency = 1** (87.0%) — sesgan la mediana hacia abajo y son transparentes en el dashboard.
- 4 **Dataset 100% sintético** — los hallazgos son consistentes pero no transferibles a operación real.
- 5 **Ventana fija de 72 meses** — los clientes nuevos quedan castigados en retention_rate (denominador rígido).

G Estadísticos clave del CLTV

N clientes con CLTV > 0	5 330
Mediana	0,83 €
Media	3 414,92 €
P75	1,78 €
P90	14 048,95 €
P99	49 027,69 €
Máximo	109 734,95 €
Cientes con freq = 1	5 000